

Projeto Final

Disciplina Métodos Estatísticos de Previsão

Isabela Ferreira Ventura Cruz

Nathalia Gabriella Ferreira dos Santos

29/11/2023

Índice

1	Descrição dos Dados	2
2	Ajustes de Modelos	4
2.1	Modelo ARIMA	4
2.1.1	Estacionariedade	4
2.1.2	Identificação do modelo	4
2.1.3	Modelo 03	4
2.1.4	Modelo 04	4
2.1.5	Modelo 05	6
2.1.6	Modelo 06	6
2.1.7	Modelo 07	6
2.1.8	Modelo 08	6
2.2	Modelo de Alisamento Exponencial	6
3	Comparação de modelos	8
3.1	Previsão usando ARIMA	8
3.2	Previsão usando Alisamento Exponencial	8
4	Conclusão	11

Capítulo 1

Descrição dos Dados

A série escolhida para realizar o trabalho foi obtida por meio da plataforma kaggle no seguinte [link](#). O banco de dados é sobre o **número mensal de passageiros de voos aéreos do ano de 1949 a 1960**, ao todo contém 144 observações. A tabela

Tabela 1.1: Resumo das 5 primeiras observações do conjunto de dados

Mes	Passageiros
1949-01	112
1949-02	118
1949-03	132
1949-04	129
1949-05	121
1949-06	135

Como o foco do projeto é realizar previsões, optou-se por retirar as 12 observações finais do conjunto de dados. Ou seja, 132 observações serão usadas para *treino* dos modelos de previsão para séries temporais e depois será comparado quão bem cada modelo usado realizou as previsões.

A Figura [1.1](#) indica o comportamento dos dados ao longo do tempo. Nota-se *comportamento crescente* além de presença de grandes picos de *sazonalidade*, a qual parece se comportar como um modelo em que a sazonalidade seja aditiva e/ou multiplicativa, ou seja, a sazonalidade muda ao longo do tempo, esse caso será melhor avaliado na Seção [2.2](#).

Gráfico da série




Figura 1.1: Gráfico da série

Capítulo 2

Ajustes de Modelos

2.1 Modelo ARIMA

2.1.1 Estacionariedade

Os modelos ARIMA de Box e Jenkins partem do pré suposto de que a série é estacionária, desse modo, o primeiro passo para uma modelagem acertiva é verificar a estacionariedade da série. Para isso foi utilizado o teste de Dickey-Fuller, em que a hipótese nula é que os dados não são estacionários, o valor-p do teste é 0,01, ou seja, rejeitamos essa hipótese e não precisaremos tomar diferenças na série ($d=0$).

2.1.2 Identificação do modelo

Para identificar o modelo foram analisados os gráficos de autocorrelação (ACF) e autocorrelação parcial (PACF). Em Figura 2.1 podemos notar que há um decaimento rápido e picos significativos nos lags múltiplos de 12, esse é um forte indicativo de sazonalidade ($S=12$). Já em Figura 2.2 podemos notar um pico significativo no lag 1, e picos significativos nos lags 8 e 10 e 12. Como a significância adotada neste trabalho é de 5%, esperamos que 5% dos valores de Φ_{kk} estejam fora dos limites esperados, desse modo, consideraremos apenas os lags 1, e 12 significativos. Desse modo, o pico no lag 12 é mais um indício de sazonalidade de ordem 12. Juntando as informações trazidas pelos gráficos da ACF e da PACF, iniciamos a análise partindo de um modelo SARIMA(1,0,0)(0,0,1)12 e o sobrefixamos, aumentando a ordem dos componentes um por um.

2.1.2.1 Modelo inicial:

O modelo inicial é um SARIMA(1,0,0)(0,0,1)12. Todos os coeficientes são significativos e o AIC é 1187.266

2.1.2.2 Modelo 02

Aumentando a ordem p chegamos a um modelo SARIMA(2,0,0)(0,0,1)12. Todos os coeficientes são significativos e o AIC (1181.575) caiu

2.1.3 Modelo 03

Aumentando a ordem p novamente chegamos a um SARIMA(3,0,0)(0,0,1)12. Nem todos os coeficientes são significativos e o AIC (1182.402) aumentou em relação ao modelo 02. Desse modo, ficamos com $p=2$ e o melhor modelo até então é o modelo 02.

2.1.4 Modelo 04

Aumentando a ordem q temos um modelo SARIMA(2,0,1)(0,0,1)12. Todos os coeficientes são significativos e o AIC (1177.668) caiu

Series serie_train




Figura 2.1: ACF

Series serie_train




Figura 2.2: PACF

2.1.5 Modelo 05

Aumentando a ordem q chegamos a um SARIMA(2,0,2)(0,0,1)12. Nem todos os coeficientes são significativos e o AIC (1184.598) aumentou. Desse modo, ficamos com q=1 e o melhor modelo até então é o modelo 04

2.1.6 Modelo 06

Aumentando a ordem P: SARIMA(2,0,1)(1,0,1)12. O ajuste não convergiu. Desse modo, ficamos com P=0

2.1.7 Modelo 07

Aumentando a ordem Q chegamos a um SARIMA(2,0,1)(0,0,2)12. Nem todos os coeficientes são significativos mas o AIC (1137.312) caiu.

2.1.8 Modelo 08

Aumentando a ordem Q temos um SARIMA(2,0,1)(0,0,3)12. Nem todos os coeficientes são significativos mas o AIC caiu. A partir daqui os modelos começam a ficar cada vez mais complicados e de convergência mais lenta, desse modo, paramos com Q=3

Tabela 2.1: Modelos SARIMA ajustados

	Modelo	Número de coeficientes	Porcentagem de coeficientes significativos	AIC
01	SARIMA(1,0,0)(0,0,1)12	3	100 %	1187.2665
02	SARIMA(2,0,0)(0,0,1)12	4	100 %	1181.575
03	SARIMA(3,0,0)(0,0,1)12	5	80 %	1182.402
04	SARIMA(2,0,1)(0,0,1)12	5	100 %	1177.668
05	SARIMA(2,0,2)(0,0,1)12	6	50 %	1184.598
06	SARIMA(2,0,1)(1,0,1)12	-	-	-
07	SARIMA(2,0,1)(0,0,2)12	6	50 %	1137.312
08	SARIMA(2,0,1)(0,0,3)12	7	86 %	1096.508

Comparando todos os modelos acima, escolhemos o melhor considerando o menor AIC e maior número de coeficientes significativos. Os modelo com menor AIC é o 08 com 6 coeficientes significativos em 7, o modelo com segundo menor AIC é o modelo 07 e possui apenas metade dos coeficientes significativos, já o modelo 04 possui todos os coeficientes significativos mas AIC elevado se comparado com os modelos 07 e 08. Diante disso, optamos por escolher o modelo 08, pois apenas um coeficiente não é significativo e o AIC é menor dentre todas as opções abordadas.

2.2 Modelo de Alisamento Exponencial

Como observado na Figura 1.1, devido a presença de sazonalidade aditiva e/ou multiplicativa, os modelo de **Alisamento Exponencial de HOLT-WINTERS** aditivo e com fator multiplicativo foram considerados a fim de avaliar o Erro Quadrático Médio de Previsão para ambos ajustes e escolher o melhor.

As constantes de suavização encontradas são:

Tabela 2.2: Constantes para ambos modelos

Constante	Modelo Aditivo	Modelo Multiplicativo
α	0.2465	0.8027

Constante	Modelo Aditivo	Modelo Multiplicativo
β	0.036	0.0085
γ	1	1

A partir das constantes encontradas, sobre os modelos, nota-se que:

- o α associado ao nível é maior no modelo multiplicativo. Ou seja, o modelo multiplicativo coloca cerca de 3 mais peso na influência das informações mais recentes sobre o nível do que o modelo aditivo.
- Em contrapartida, o β associado a tendência é 4 vezes maior no modelo aditivo, o que implica que o modelo aditivo coloca mais peso na influência das informações mais recentes sobre a tendência.
- Por fim, ambos colocam pesos iguais ao γ associado a sazonalidade. Como o peso é 1, indica que toda sazonalidade pode ser explicada pelas informações recentes.

Além disso, foi calculado o Erro Quadrático Médio de Previsão para ambos ajuste, como:

$$EQMP_{Aditivo} = 1.8127548 \times 10^4 < 2.0768381 \times 10^4 = EQMP_{Multiplicativo},$$

o modelo aditivo deve ser preferível para modelar a série, logo, ele será usado para previsão a ser feita na Seção 3.

Capítulo 3

Comparação de modelos

3.1 Previsão usando ARIMA

Os valores preditos usando o modelo final obtido na Seção 2.1 estão contidos na Tabela 3.1, uma coluna foi adicionada indicando se o Intervalo de Confiança contém ou não o valor real da série. Nesse caso, apenas para o 7º mês foi observado que o valor real não estava contido no intervalo.

Tabela 3.1: Previsão modelo SARIMA(2,0,1)(0,0,1)₁₂

real	fit	lwr	upr	ConclusaoIC
417	431	406	456	Contém ajuste
391	413	377	449	Contém ajuste
419	452	410	495	Contém ajuste
461	442	394	491	Contém ajuste
472	465	413	517	Contém ajuste
535	492	436	548	Contém ajuste
622	561	502	620	Não contém ajuste
606	560	498	621	Contém ajuste
508	486	422	550	Contém ajuste
461	445	379	511	Contém ajuste
390	409	341	477	Contém ajuste
432	448	378	517	Contém ajuste

Além disso, a Figura 3.1 indica o comportamento das previsões feitas junto a série usada para treino. Nota-se que os intervalos estão mais próximos do valor ajustado, o que indica que com mais certeza (menor variabilidade) o modelo consegue prever o valor real.

3.2 Previsão usando Alisamento Exponencial

Os valores preditos usando o modelo final obtido na Seção 2.2 estão contidos na Tabela 3.2, uma coluna foi adicionada indicando se o Intervalo de Confiança contém ou não o valor real da série. Nesse caso, apenas para o 3º mês foi observado que o valor real não estava contido no intervalo.




Figura 3.1: Valores preditos para o modelo SARIMA(2,0,1)(0,0,1)12

Tabela 3.2: Previsão AEWH-Aditivo

real	fit	lwr	upr	ConclusaoIC
417	417	393	441	Contém ajuste
391	399	374	423	Contém ajuste
419	460	434	485	Não contém ajuste
461	448	422	475	Contém ajuste
472	470	443	497	Contém ajuste
535	525	497	553	Contém ajuste
622	598	569	627	Contém ajuste
606	605	575	635	Contém ajuste
508	506	475	536	Contém ajuste
461	449	418	481	Contém ajuste
390	404	371	437	Contém ajuste
432	444	410	477	Contém ajuste

Além disso, a Figura 3.2 indica o comportamento das previsões feitas junto a série usada para treino. Nota-se que os intervalos estão bem próximos do valor ajustado, o que indica que com mais certeza (menor variabilidade) o modelo consegue prever o valor real.




Figura 3.2: Valores preditos para modelo AEWH-Aditivo

Capítulo 4

Conclusão

Dado o discutido nesse trabalho, pelo observado das previsões obtidas na Seção 3, conclui-se que o modelo que resultou nas melhores previsões e portanto entende-se ser o melhor, foi